

72 小时实验：实时互动场景产品

项目背景

请你作为架构师，为一款结合实时语音、角色表演以及图片和视频等多模态内容的产品做方案设计和 MVP 实现。

请从零实现一个移动端网页适配优先的互动场景。不是传统的聊天消息列表：用户面对的是一个处于具体环境中的角色，可以通过文字或语音和角色互动；角色会说话、改变表情或动作，并根据交流过程触发场景演出。

时间和工具

- 提交窗口为收到题目后的 72 小时，建议在 README 中记录大致投入时间。
- 可以并鼓励使用 Codex、Claude Code、Cursor、v0 等 AI 编程工具。
- 可以自由选择前端、后端、模型、实时音频和媒体技术方案。
- 不要求训练或微调模型。

基础场景

你可以自行设计一个简短场景，也可以使用下面的故事种子：

暴雨后的夜晚，用户在一家即将打烊的咖啡馆遇到 Mira。Mira 是一名 26 岁的旅行摄影师，穿着琥珀色雨衣，戴着银色星星发夹。她似乎在等待某个人，但不愿直接说出原因。

体验应使用原创成年角色。剧情创作本身不需要复杂，能够支撑一次连续的 3–5 分钟互动即可。

核心体验

1. 页面

- 页面以场景和角色为视觉主体，不使用传统聊天消息列表作为主要界面。
- 包含背景、角色、字幕区域以及文字和语音交互入口。
- 适配移动端，桌面端可以正常体验。
- 至少呈现以下角色状态：待机、倾听、思考、说话。
- 用户能够从画面中感知角色当前所处的状态。

2. 文字和语音互动

- 用户可以输入文字与角色交流。

- 用户可以通过麦克风与角色交流。
- 角色使用语音回复，并同步显示字幕。
- 一次会话中可以连续完成多轮互动。
- 语音可以采用端到端实时语音模型，也可以采用 STT、语言模型和 TTS 组合方案。

3. 语音打断

当角色正在说话时，用户应当能够开始新的语音输入并打断角色。

打断发生后：

- 当前角色语音立即停止。
- 当前尚未完成的回复被取消或失效。
- 尚未播放的字幕、动作和媒体事件不会继续出现。
- 页面切换到倾听状态，并开始处理用户的新输入。
- 上一轮迟到的网络响应不会覆盖当前状态或重新开始播放。

可以使用自动语音活动检测，也可以设计明确的按住说话或点击打断交互。请在 README 中说明选择该方式的原因。

4. 角色和场景驱动

角色回复除文本或语音外，还应能够驱动画面变化。请设计一种结构化的角色或场景指令，表达例如：

- 当前情绪
- 表情或姿势
- 动作
- 场景或镜头变化
- 特效
- 可选剧情分支
- 图片或视频事件

不限定具体协议格式。至少实现：

- 3 种可以辨认的情绪或表情；
- 2 种非说话动作或视觉状态；
- 1 次背景、镜头或环境变化；
- 1 个由当前对话内容触发的明显视觉事件。

视觉事件不能只按照固定计时器播放，需要和当前回复、角色状态或剧情节点有关。

5. 一种多模态表现能力

从下面选择至少一种集成到完整体验中：

- Live2D、Rive、Spine、序列帧或其他角色动画；
- 由角色状态驱动的 MP4/WebM 剧情片段；
- 根据当前对话动态生成的场景图片；
- 根据当前对话或图片生成的短视频。

使用视频时，需要处理加载、播放结束和用户中途打断。使用生成式媒体时，需要向用户呈现生成中的状态，并处理失败情况。

6. 可运行的前后端闭环

- 页面、服务端和模型调用可以完整运行。
- 会话内的角色和场景状态能够连续变化。
- 对模型超时、断线、音频或媒体加载失败提供基本反馈和恢复方式。
- 快速连续输入或打断时，不应播放已经失效的回复。
- 提供无需私人 API 密钥也能查看核心流程的方式，例如 Mock 模式或录制回放模式。

可选扩展

完成核心体验后，可以根据时间选择任意方向继续探索。以下内容均不是必须项。

实时语音

- 自动检测用户开口并完成自然打断；
- 区分真正的打断与“嗯”“对”等附和；
- 回声消除，避免角色听到自己的声音；
- 流式字幕；
- 展示语音首包延迟或关键阶段耗时；
- 断线重连和会话恢复。

角色表演

- 口型同步；
- 眨眼、呼吸、视线和待机行为；
- 动作优先级、中断和自然衔接；
- 情绪之间的平滑过渡；
- 音频驱动的角色动作；

- 配置驱动的角色资源和动作系统。

视频演出

- 视频片段预加载和无黑屏切换；
- 字幕、语音和视频时间线同步；
- 全屏剧情片段和常驻角色之间的衔接；
- 视频加载失败后的动画或静态画面降级；
- 透明视频、遮罩或分层合成。

生成式图片和视频

- 使用角色参考图生成新的剧情场景；
- 保持人物外观、服装和环境的连续性；
- 在关键剧情节点生成短视频；
- 生成期间使用现有角色动画承接体验；
- 缓存和复用已经生成的内容；
- 对明显失败的生成结果进行检测或重新生成。

工程扩展

- 支持替换不同的模型或媒体 Provider；
- 统一传递和处理取消信号；
- 记录一次互动中的主要状态事件；
- 支持会话回放或问题诊断；
- 添加自动化测试；
- 给出延迟、错误和模型调用情况的简单观测页面。

技术和素材

- 可以使用任何合理的开源库、商业 API 或本地模型。
- 可以使用自制、开源或 AI 生成的视觉和音频素材。
- 请在 README 中注明主要第三方服务和素材来源。
- 请勿在仓库中提交 API 密钥或其他私人凭证。
- 如果某项外部服务无法提供公开演示，请通过 Mock 或回放方式保证项目仍可体验。

交付内容

请提交以下内容：

1. 源代码仓库。
2. 可访问的演示地址，或清晰的本地启动说明。
3. 一条命令完成本地启动；如果无法做到，请确保完整启动过程可在 15 分钟内完成。
4. 一段 3–5 分钟的演示录屏，展示：
 - 文字或语音互动；
 - 角色状态和画面变化；
 - 在角色说话时成功打断；
 - 所选择的动画、视频或生成媒体能力；
 - 至少一种失败或降级状态。
5. README，内容包括：
 - 系统结构和主要模块；
 - 语音交互与打断流程；
 - 角色和场景指令的设计；
 - 使用的模型、媒体方案和主要第三方服务；
 - 关键技术选择与取舍；
 - 已知问题；
 - 大致投入时间；
 - 如果继续开发两周，准备如何演进当前实现。
6. AI_USAGE.md，简要说明：
 - 使用了哪些 AI 工具；
 - AI 主要参与了哪些工作；
 - 哪些关键结果经过了人工验证；
 - 一个 AI 生成结果存在问题、你发现并修正它的例子。

不需要完成

- 完整注册和账号系统；
- 支付、订阅或虚拟货币；
- 管理后台；
- 角色市场或社区；
- 原生 iOS 或 Android 客户端；
- 模型训练或微调；
- 多角色、多章节或完整游戏内容；
- 大规模生产环境基础设施。

如果某个能力没有完成，请在 README 中说明当前状态、遇到的问题以及下一步方案。一个范围清晰、能够稳定运行的版本即可。